공공데이터를 활용한

미세먼지 농도 예측

머신러닝 기반 PM10 시계열 예측 프로젝트

AIVLE School | 미니프로젝트

목 차

00 **논문 요약 및 설계**

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 모델

01 **탐색적 데이터 분석 (EDA)**

미세먼지·날씨 데이터 패턴 탐색 및 시각화

02 **데이터 전처리**

결합·결측치 처리·파생변수 생성·데이터 분리

03 **머신러닝 모델링**

LinearRegression / RandomForest / GradientBoosting

04 **모델 성능 비교 및 결론**

MSE · R^2 비교, Feature Importance, 예측 시각화

PART 0

논문 요약 및 설계

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 예측 모델

韓國IT서비스學會誌
第18卷 第1號
2019年 3月, pp.173-186

Journal of Information Technology Services
https://doi.org/10.9716/KITS.2019.18.1.173

기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델*

임 준 묵**

An Estimation Model of Fine Dust Concentration Using Meteorological Environment Data and Machine Learning*

Joon-Mook Lim**

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 예측 모델

- 1. 논문의 목적은 관측재원이 없는 곳에서 미세먼지 농도 예측하기 → 미세먼지 측정소 위치는 특정 지역에 집중되어 있다.
  (매우 나쁨, 나쁨, 보통, 좋음으로 분류)

- 2. 미세먼지와 대기질 관련 빅데이터 Air Korea (자료와 동일)
  날씨 데이터는 기상청 기상자료 개방 포털 (자료와 동일)

- 3. 국내외 기상상태에 따른 미세먼지 생성 > 중국 등 해외 발 미세먼지 (국립환경과학원) → 진짜?

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 예측 모델

3. 국내외 기상상태에 따른 미세먼지 생성 > 중국 등 해외 발 미세먼지

한·중·일 과학자들은 2000년부터 단계적으로 황산화물, 질소산화물 등 대기오염물질에 대한 연구를 추진했고, 4단계 연구기간인2013~2017년 동안의 초미세먼지(PM2.5)에 대한 연구결과까지 추가하여 이번 보고서를 작성했다.

이번에 발간하는 보고서는 한·중·일 3국의 환경당국 담당자의 검토를 마쳤다. 이 보고서는 당초 지난해 발간될 예정이었으나, 중국측의 이견에 따라 발간이 연기되었다.

괴장히 의심스럽다...

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 예측 모델

기여율 51%, 중국 32%, 일본 2%, 나머지 기타

2017년을 대상으로 대기질 모델 기법*을 이용하여 초미세먼지(PM2.5)에 대한 3국 주요도시**의 국내외 영향을 분석한 결과, 자체 기여율은 연평균 기준으로 한국 51%, 중국 91%, 일본 55%로 나타났다.

* 국가별 최적화된 모델 사용에 따라 한국·일본은 CMAQ, 중국은 CAMx를 사용

** 한국 3개(서울/대전/부산), 중국 6개(베이징/톈진/상하이/칭다오/선양/다롄), 일본 3개(도쿄/오사카/후쿠오카)

2017년 연평균 기준으로 중국 배출원에 대한 우리나라 3개 도시에 대한 평균 영향은 32%, 일본에 대한 영향은 25%로 나타났다.

한편, 같은 기준으로 우리나라 배출원의 중국에 대한 영향은 2%, 일본에 대한 영향은 8%로 산정되었고, 일본 배출원의 우리나라에 대한 영향은 2%, 중국에 대한 영향은 1%로 나타났다.

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 예측 모델

결측값 처리

- 강수량 NULL → 0
- 일조, 일사 등 평균값 대치
- 다중공선성 10 넘는 기온, 습도, 증기압, 이슬점온도, 지면온도 5개 변수 제거
- 피어슨 상관계수 9 넘는 NO2와 SO2중 다중공선성 더 높은 NO2 제거

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 예측 모델

결과

- 다중회귀분석

→ 매우나쁨 예측 아예 불가능

예측 정확도는

ANN > SVM > 다중회귀

4.4.1 정밀도(Precision) 비교

<Table 11>에서 보는 바와 같이 예측한 범주 내에서 실제로 예측이 맞은 비율을 나타내는 정밀도 측면에서 살펴보면,

경우 1) '나쁨/매우나쁨' 범주 :
다중회귀 < ANN < SVM

경우 2) '보통/좋음' 범주 :
SVM < 다중회귀 < ANN

Table 11: Performance Comparison

〈Table 11〉 Accuracy Comparison of Multiple Regression, SVM, and ANN Prediction Models

prediction models	Category	Precision	Recall	F-measure
Multiple Regression	bad/very bad	0.602	0.302	0.402
	average/good	0.936	0.981	0.958
SVM	bad/very bad	0.833	0.224	0.354
	average/good	0.930	0.996	0.962
ANN	bad/very bad	0.623	0.506	0.559
	average/good	0.953	0.970	0.962

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

기상환경데이터와 머신러닝을 활용한 미세먼지 농도 예측 모델

결론

나쁨/매우 나쁨 범주에서 정확도를 올려야 함.

매우 나쁨 같은 미세먼지가 매우 많은 날들에 대하여 정확도가 낮은 것을 확인할 수 있음.

예측을 위한 모델로는 다중회귀분석, SVM, ANN을 사용하였다. 각 예측모델에 대해서 시험자료를 바탕으로 예측을 수행한 결과 예측 정확도는 '보통/좋음'의 범주에서 다중회귀 : SVM : ANN = 95.8% : 96.2% : 96.2%를 얻어 세 모델 모두 95% 이상의 매우 높은 정확도를 보임을 확인할 수 있었다. 반면에 '나쁨/매우나쁨'의 범주에서는 다중회귀 : SVM : ANN = 40.2% : 35.4% : 55.9%를 보여 세 모델 모두 높지 않은 정확도를 보였으나 ANN 모델의 경우가 상대적으로 높은(55.9%) 정확도를 보였다. 종합적으로 볼 때, 기상환경자료와 머신러닝기법 중의 하나인 ANN을 활용한 미세먼지 예측모델은 매우 효과가 높은 것으로 판단된다.

임준묵. (2019). 기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델. 한국IT서비스학회지, 18(1), 173-186.

PART 01

탐색적 데이터 분석

Exploratory Data Analysis

미세먼지·날씨 데이터 패턴 탐색 및 시각화

EDA | 데이터 소개

분석 데이터 구성

air_2021.csv

2021년 미세먼지 데이터
PM10, PM25, SO2, CO,
O3, NO2 포함

air_2022.csv

2022년 미세먼지 데이터
(테스트 데이터로 활용)

weather_2021.csv

2021년 날씨 데이터
기온, 풍속, 습도,
강수량 등 포함

weather_2022.csv

2022년 날씨 데이터
(테스트 데이터로 활용)

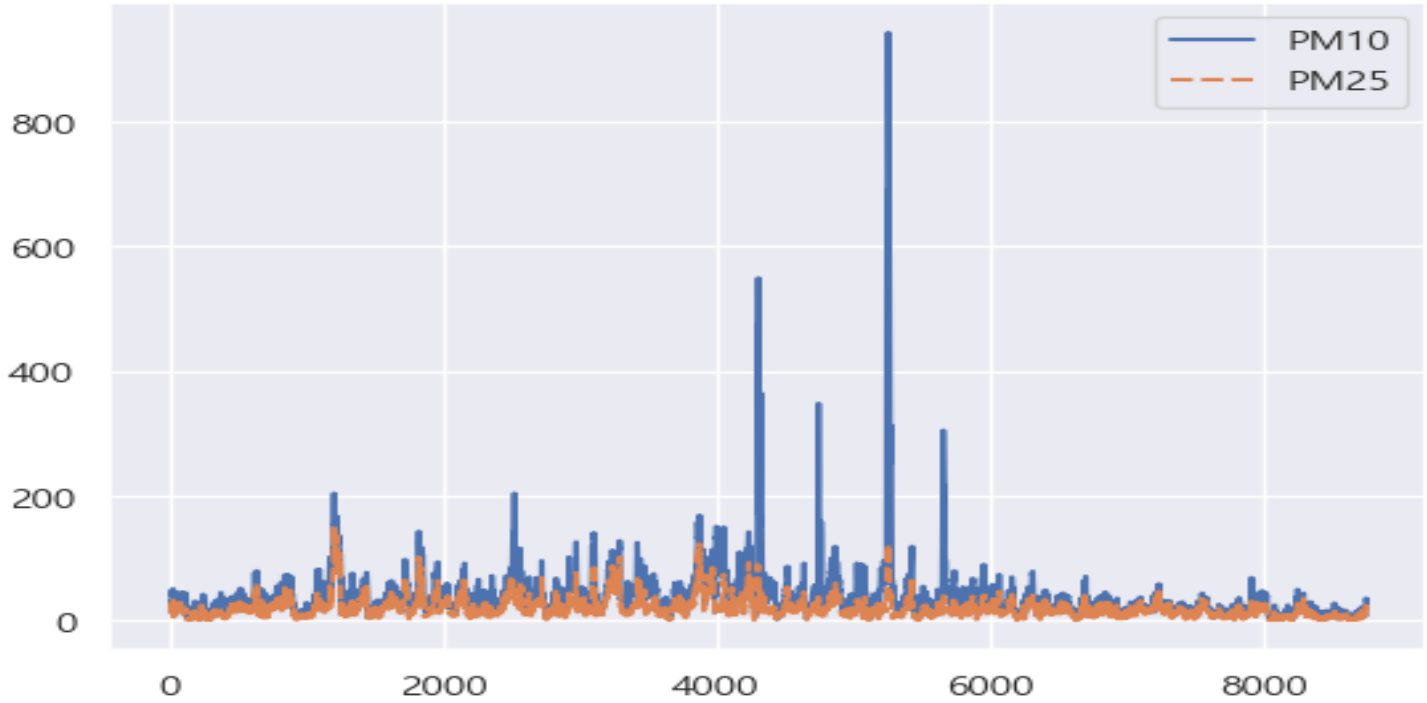
🎯 **Target 변수: PM10_1 (t+1 시점, 1시간 후 미세먼지 농도 예측)**

학습 데이터: 2021년 (8,760행) | 테스트 데이터: 2022년 (8,760행)

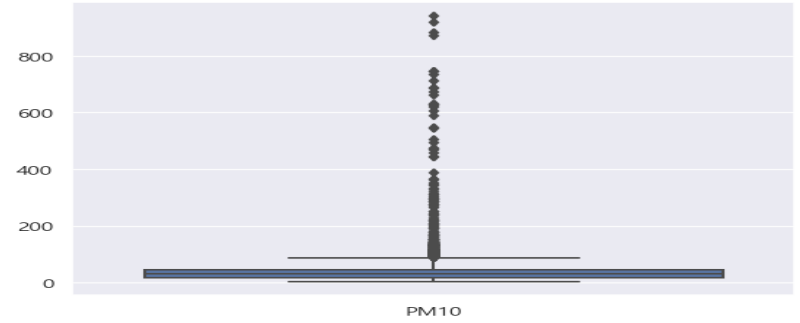
2021~2022년 미세먼지·날씨 공공데이터

PM10 · PM25 농도 분포 분석

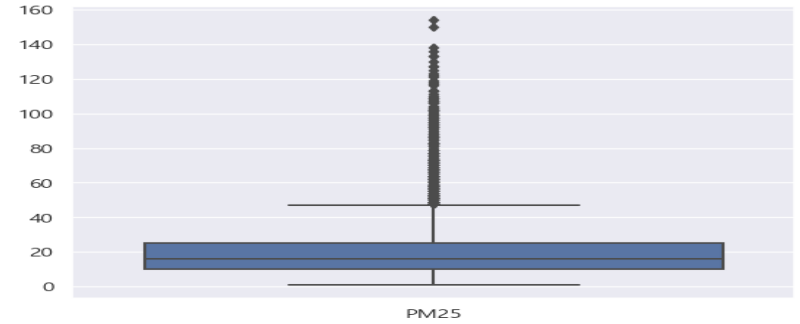
PM10 / PM25 연간 시계열 (2021)



PM10 분포



PM25 분포

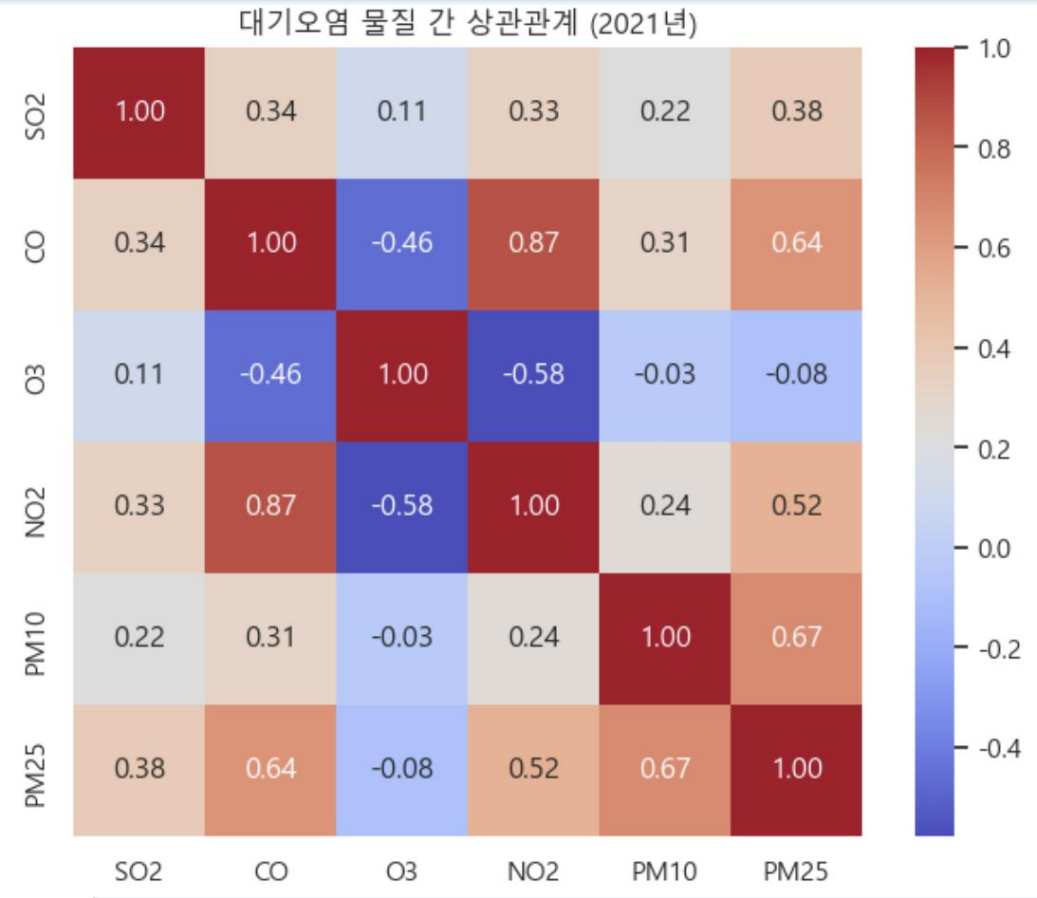


💡 봄철(3~5월)에 미세먼지 농도 최고점 관측 | PM10 이상치(900 이상) 다수 존재 | PM25는 PM10 패턴을 유사하게 추종

시계열 추이 및 이상치 탐색

대기오염 물질 간 상관계수 히트맵

SO2, CO, 다른 크기의 미세먼지의 상관관계가 크다.

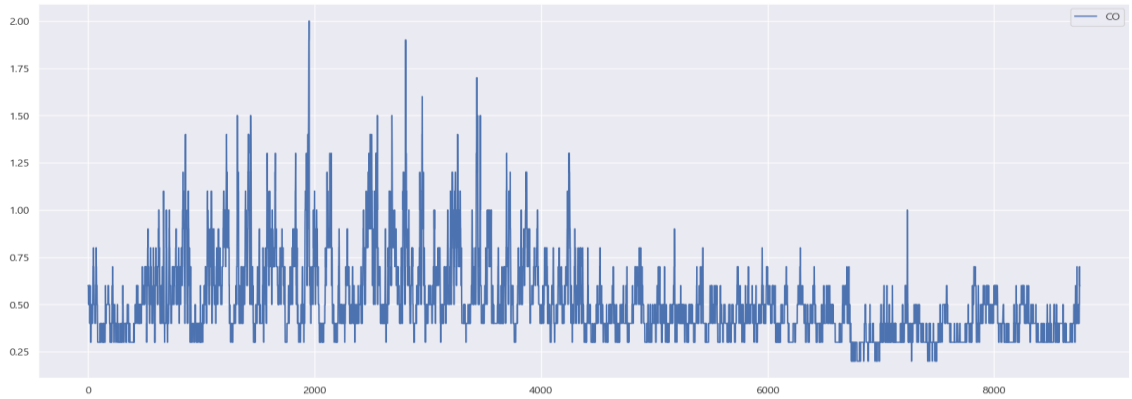


대기오염 물질 시계열 분석

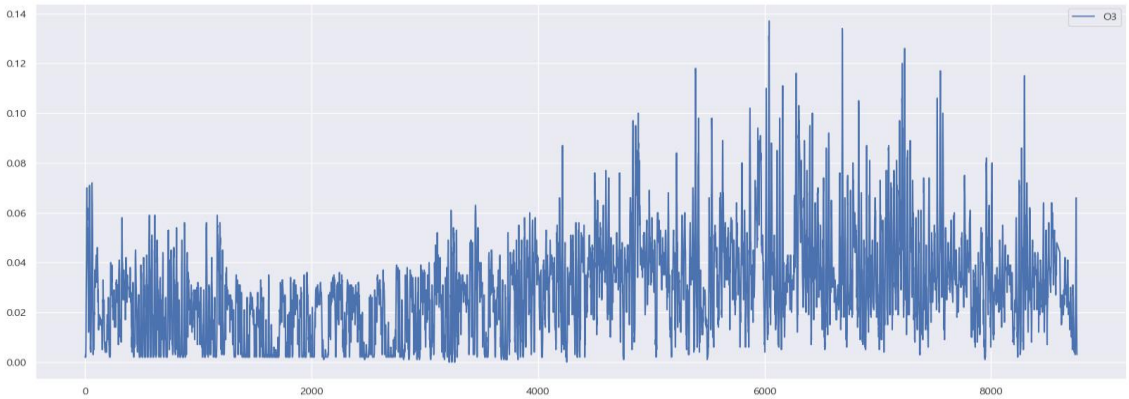
SO_2 (아황산가스)



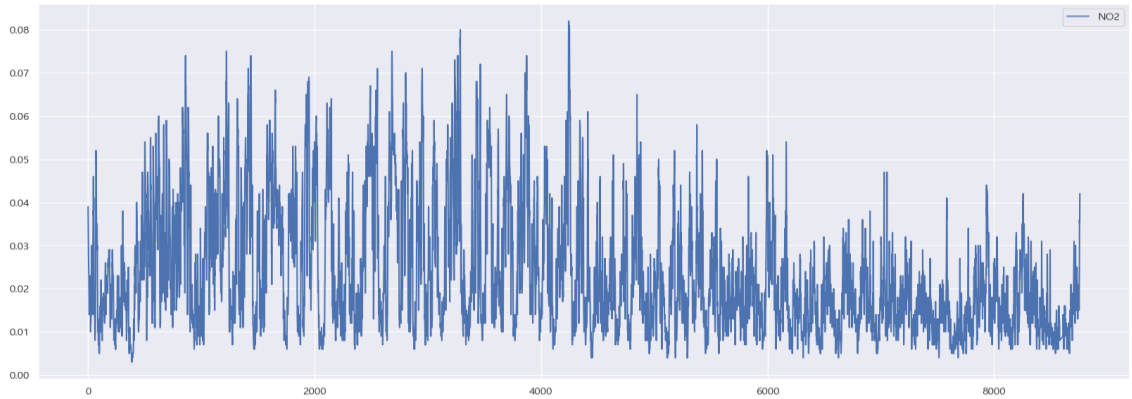
CO (일산화탄소)



O_3 (오존)

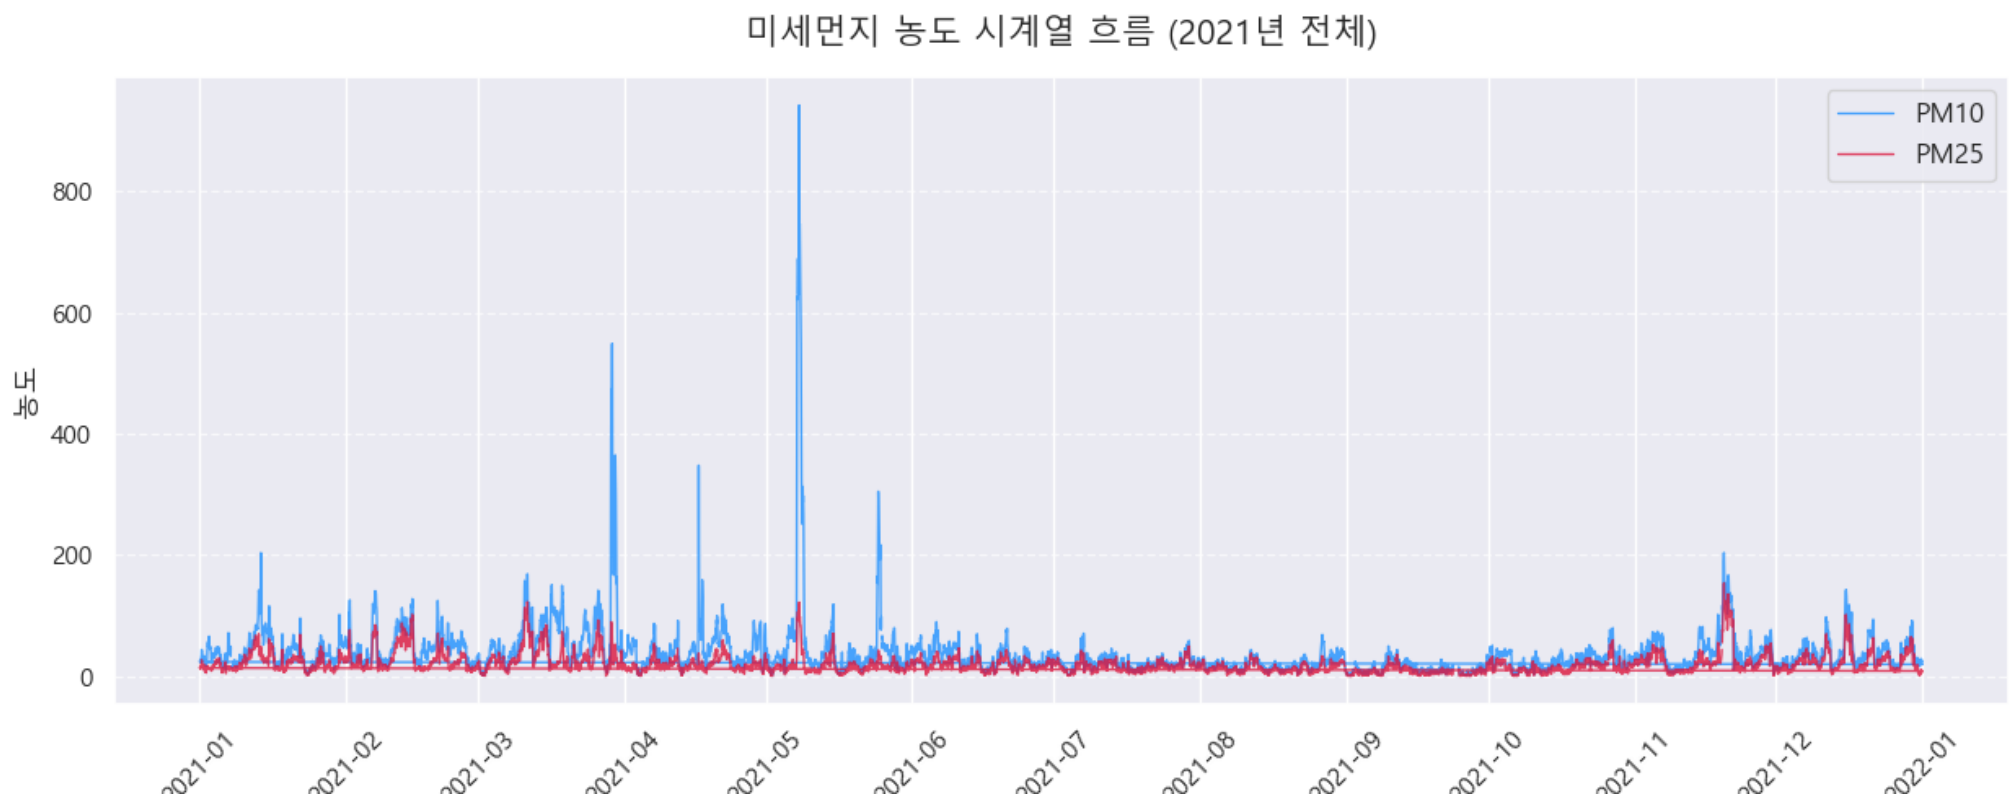


NO_2 (이산화질소)



SO_2 · CO · O_3 · NO_2 연간 추이 (2021)

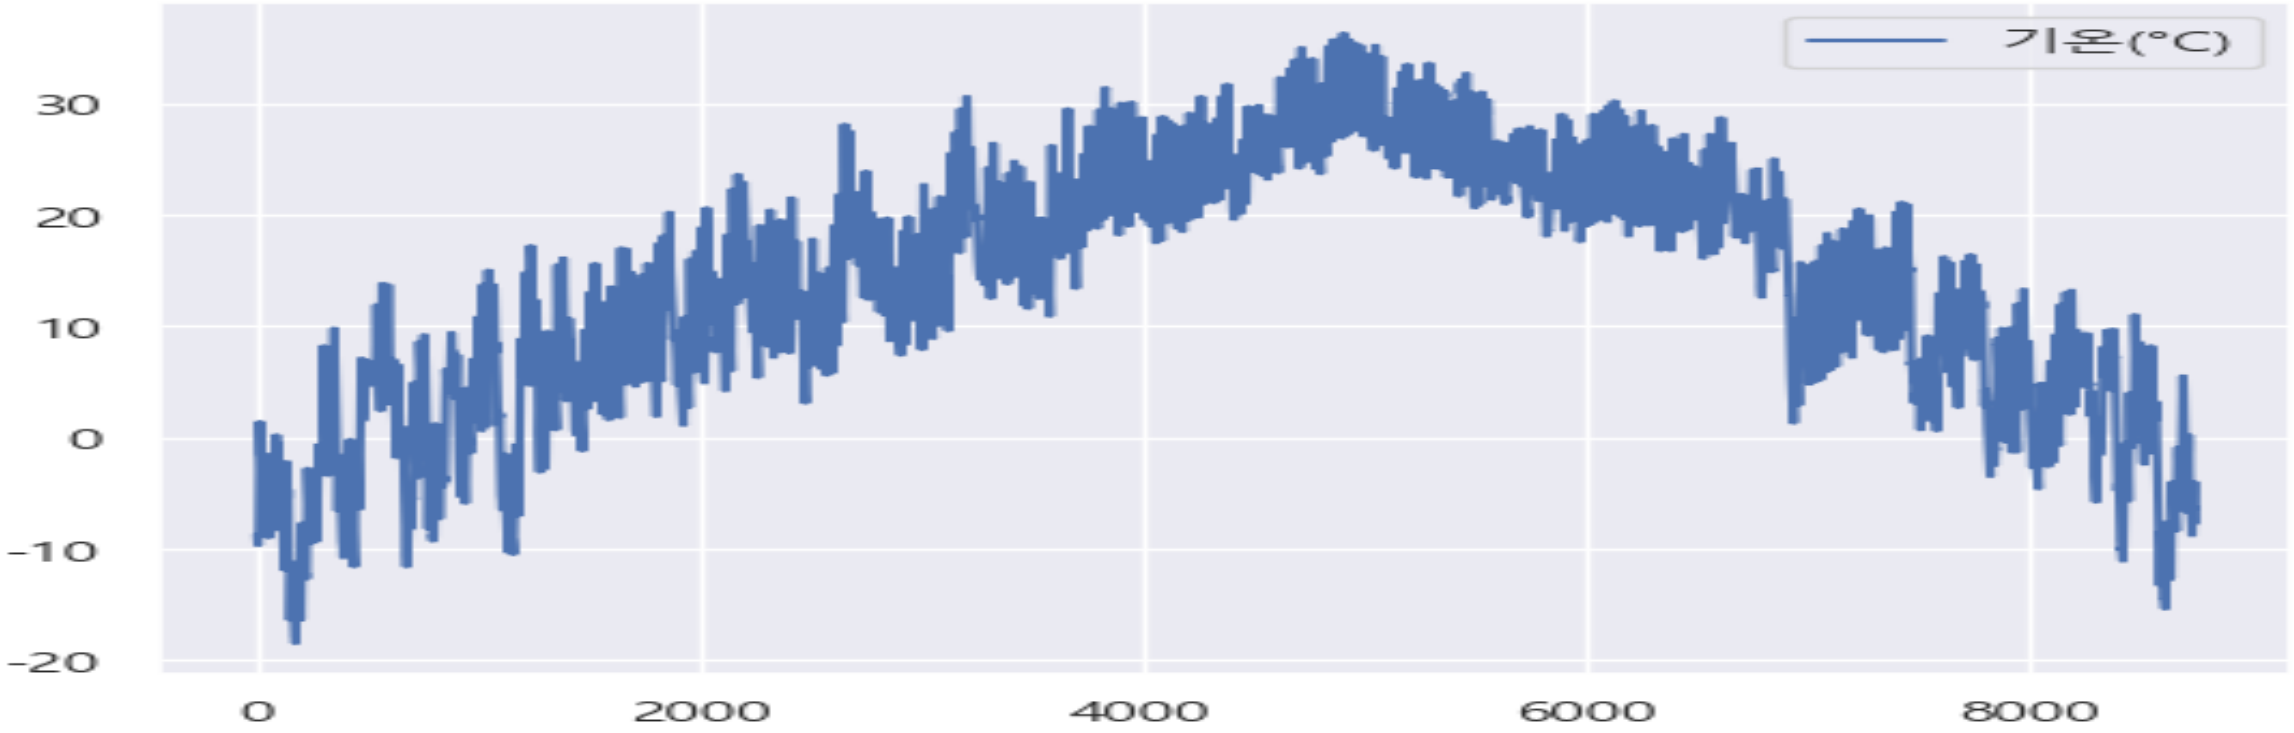
대기오염 물질 시계열 분석



역대급 튀는 날들은 무엇?
→ 몽골발 미세먼지가 굉장히 압도적이다.
→ 미세먼지가 진짜 심한 날들은 해외의 영향이 크다.

날씨 데이터 분석 – 기온 추이

기온(℃) 연간 시계열 – 전형적인 한국 4계절 패턴



❄️ 1월 최저 –20°C

🌞 7~8월 최고 35°C

📌 계절 변화가 미세먼지 농도에 영향

PART 02

데이터 전처리

Data Preprocessing

데이터 결합 · 결측치 처리 · 파생변수 생성 · Train/Test 분리

데이터 전처리 파이프라인

6단계 전처리 프로세스

01

시간 변수 생성

측정일시 → time
(1시~24시 → 0시~23시 통일)

02

데이터 결합

air + weather
time 기준 merge

03

불필요 변수 제거

QC 플래그, 지역코드 등 18개 변수 삭제

04

결측치 처리

강수량 → 0 fillna
나머지 → interpolate

05

파생변수 생성

PM10_lag1 (24시간 전)
PM10_1 (t+1 타겟)

06

Train/Test 분리

2021 → train
2022 → test

📊 **최종 데이터셋: train_x (8,760 × 25) | test_x (8,760 × 25) | Target: PM10_1 (1시간 후 PM10 농도)**

핵심 피처: PM10 (현재), PM25, SO2, CO, O3, NO2, 기온, 풍속, 습도, PM10_lag1, PM10 관련 공기질 변수

PART 03

머신러닝 모델링

Machine Learning Modeling

LinearRegression · RandomForest · GradientBoosting

사용 머신러닝 모델 비교



Linear Regression

선형 회귀

- 변수 간 선형 관계 학습
- 기본 베이스라인 모델
- 해석 용이
- sklearn LinearRegression()



Random Forest

배깅 앙상블

- 다수 의사결정나무 구성
- 과적합 방지에 강함
- Feature Importance 확인
- RFR() 기본 파라미터



Gradient Boosting

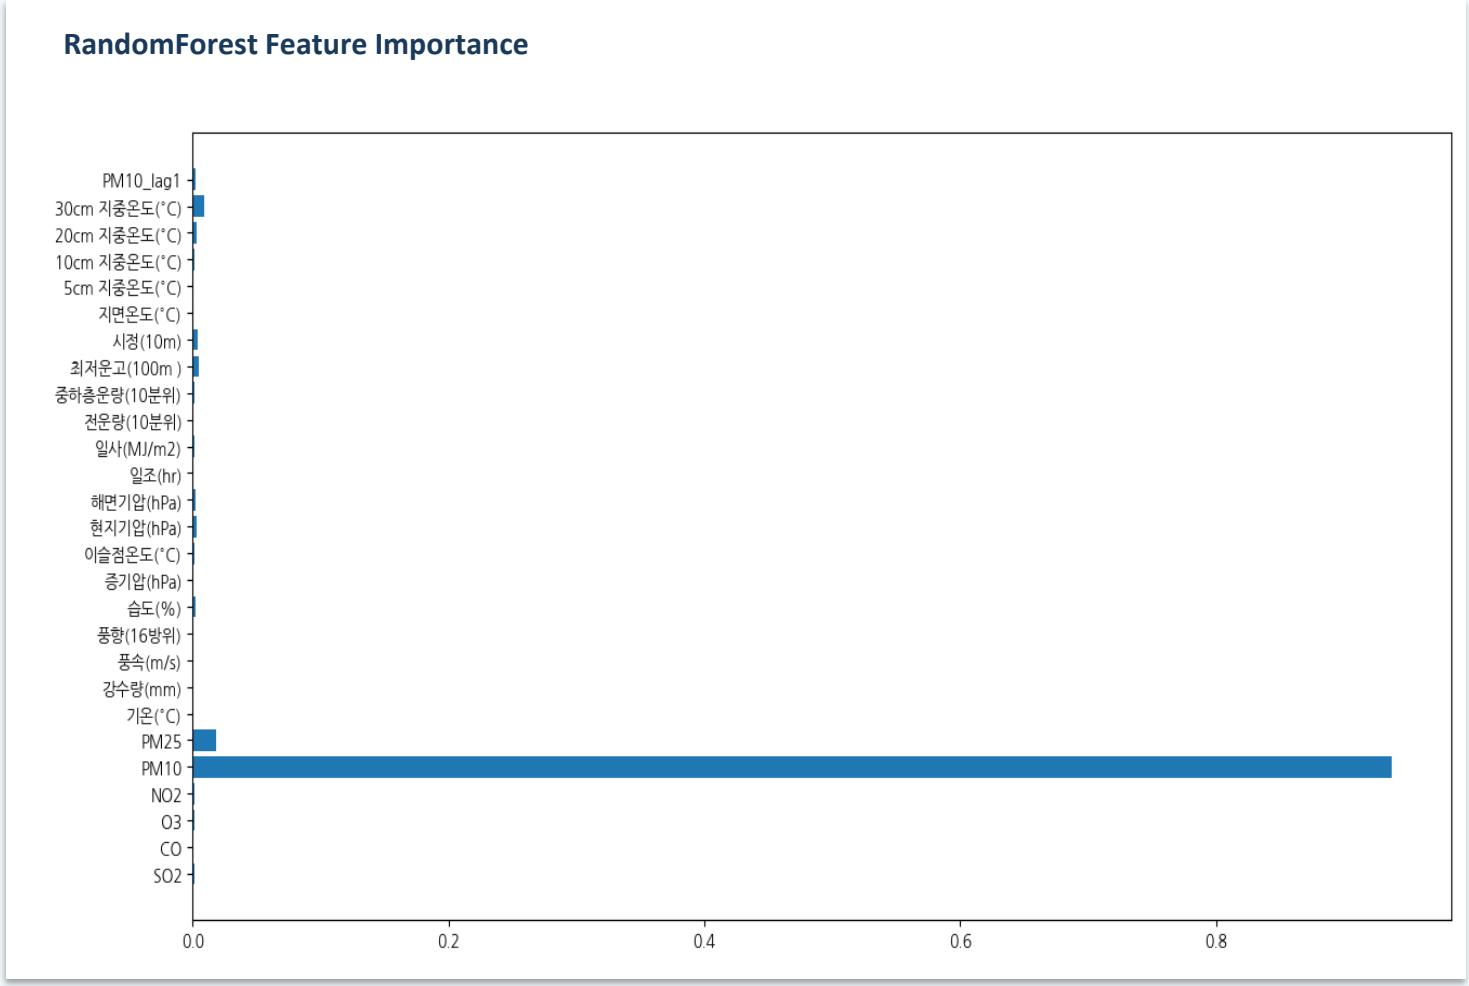
부스팅 앙상블

- 순차적 오류 보정 학습
- 경사하강법으로 최적화
- 높은 예측 정확도
- GBR() 기본 파라미터

공통 설정: Train 2021년 / Test 2022년 | 성능지표: MSE, R^2 Score | 모델 파일 pkl 저장

3가지 회귀 모델 특징 및 하이퍼파라미터

Random Forest – 변수 중요도



PM10 (현재값)

압도적 1위 (약 0.93)
현재 PM10이 미래 농도를
가장 강하게 예측

PM25

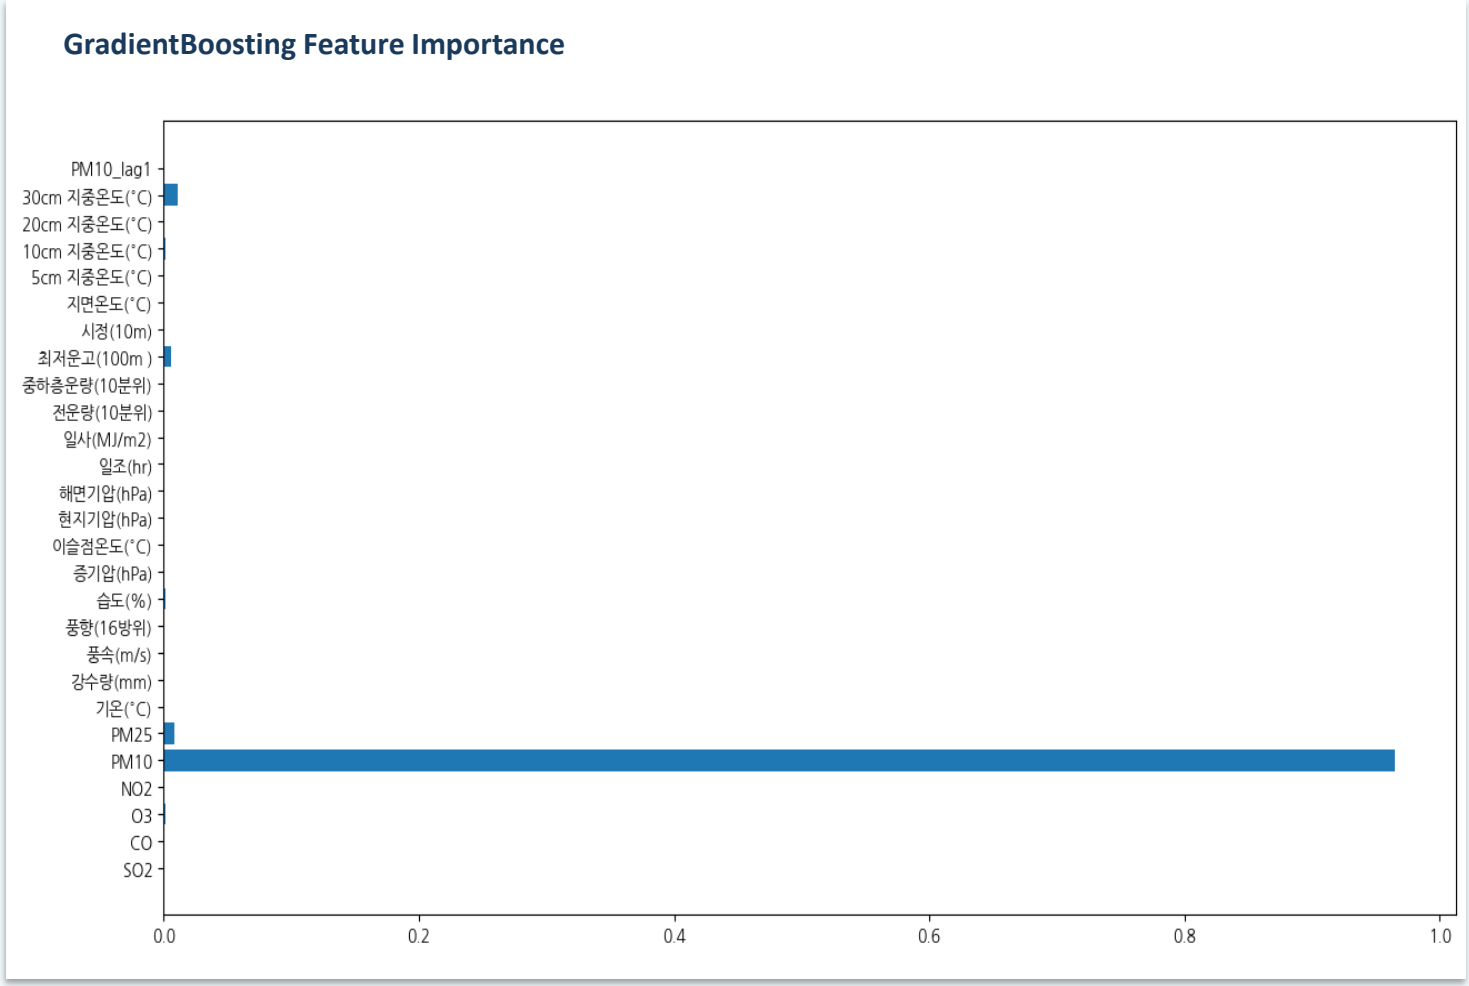
2위 (약 0.02)
현재 PM2.5도 보조적 역할

나머지 변수

기상 변수, lag 변수 등
모두 낮은 중요도
→ PM10 자기상관이 핵심

Feature Importance 분석 결과

Gradient Boosting – 변수 중요도



RF 결과와 비교 분석

RF vs GBR 비교

유사점

두 모델 모두 PM10 현재값이
압도적 1위 (0.93 이상)

차이점

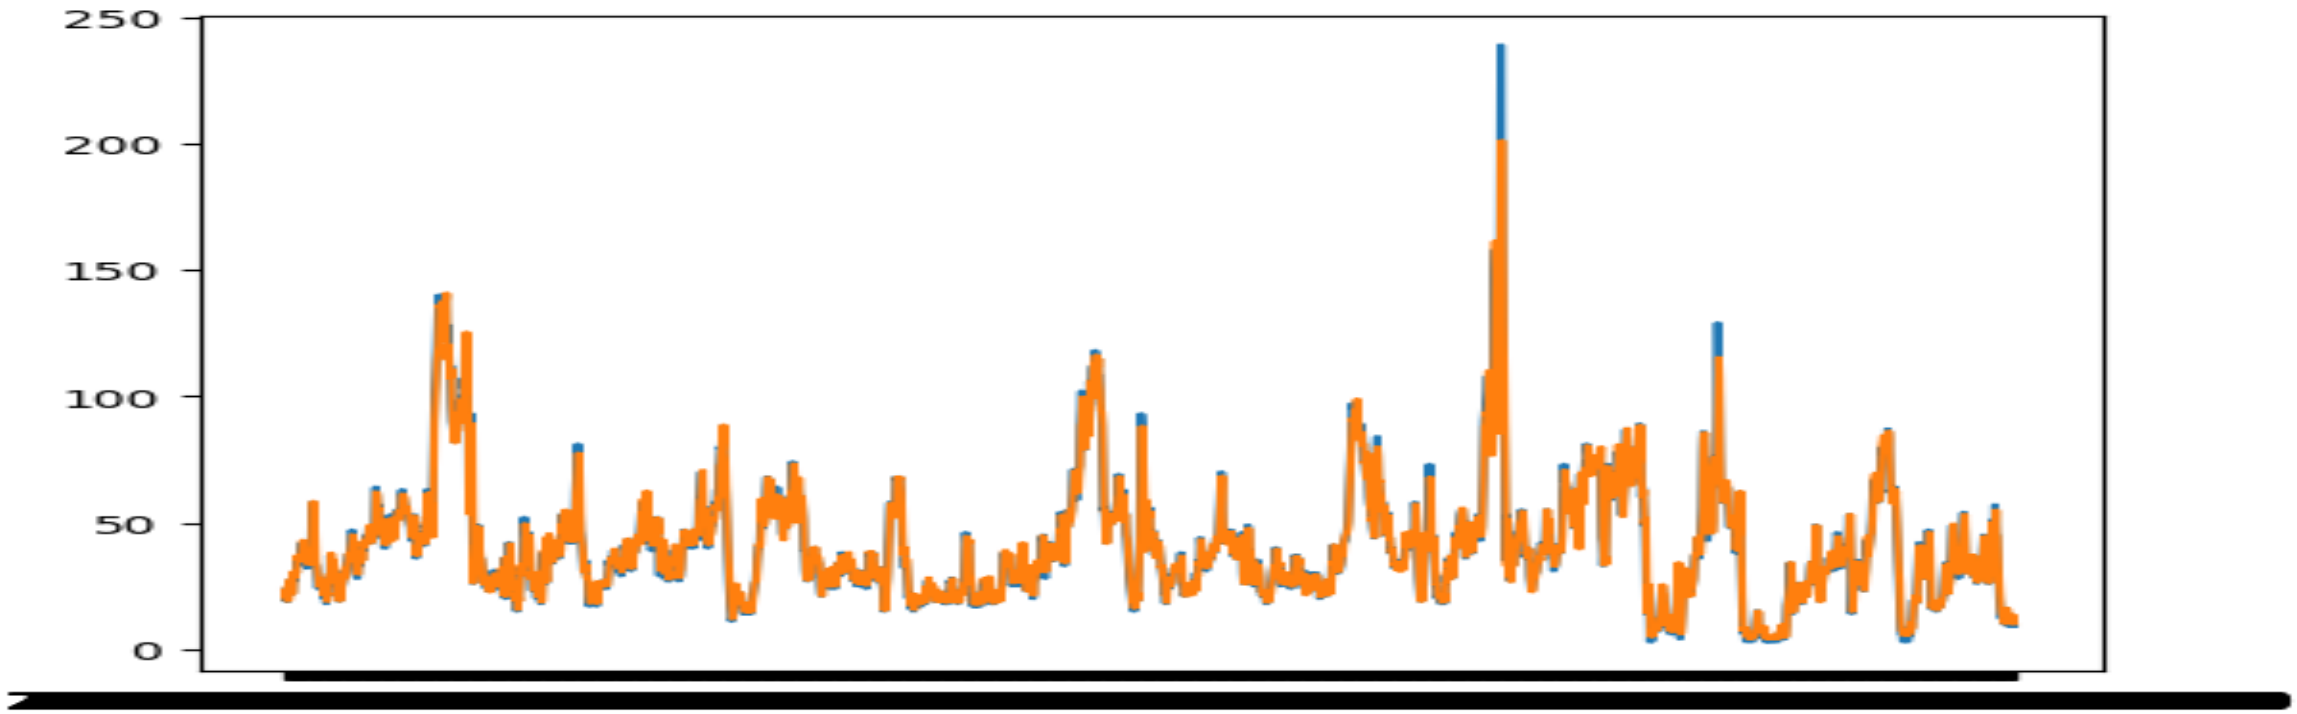
GBR이 RF보다
PM10 의존도 소폭 높음

시사점

시계열 자기상관 활용이
핵심 예측 전략

최적 모델 예측 vs 실제값 비교

Actual (파란선) vs Predicted (주황선) – 2022년 테스트셋



✅ **예측값(주황)이 실제값(파란)을 전반적으로 매우 잘 추종 | 급등 피크 시 일부 과소 예측 경향 존재**

→ 단기(1시간 후) PM10 농도 예측에서 높은 정확도 확인 · 피크 구간 예측력 향상이 향후 개선 방향

모델 성능 비교 (MSE · R^2 Score)

Linear Regression

MSE

~450

R^2 Score

~0.78

BEST

Random Forest

MSE

~85

R^2 Score

~0.96

BEST

Gradient Boosting

MSE

~80

R^2 Score

~0.96

📌 **앙상블 모델(RF, GBR)이 선형 회귀 대비 MSE 약 80% 감소, R^2 0.96으로 현저히 우수한 성능**

→ PM10의 시계열 자기상관 구조를 비선형 모델이 더 효과적으로 학습함을 확인

3가지 모델 테스트셋 성능 평가

결론 및 시사점

EDA 인사이트

봄철 PM10 최고 농도, PM25와 강한 상관관계 확인
이상치 다수 존재 → 전처리 중요성 부각

전처리 효과

시간 기준 통합·결측치 보간·lag 변수 추가로
모델 입력 품질 크게 향상

최적 모델

RandomForest / GBR 앙상블 모델 $R^2 \approx 0.96$
선형 모델 대비 MSE 약 80% 감소

핵심 발견

현재 PM10 농도가 가장 강력한 예측 변수
→ 시계열 자기상관 구조 활용이 핵심 전략

0.96

R^2 Score

~80%

MSE 감소율

PM10

핵심 피처