기상예측 2차

AI+X 중급 2조

韓國IT서비스學會誌
第18卷 第1號
2019年 3月, pp.173-186

Journal of Information Technology Services
https://doi.org/10.9716/KITS.2019.18.1.173

기상환경데이터와 머신러닝을 활용한 미세먼지농도 예측 모델*

임 준 묵**

An Estimation Model of Fine Dust Concentration Using Meteorological Environment Data and Machine Learning*

Joon-Mook Lim**

특이 사항

- 1. 논문의 목적은 관측재원이 없는 곳에서 미세먼지 농도 예측 하기 → 미세먼지 측정소 위치는 특정 지역에 집중되어 있다.
  (매우 나쁨, 나쁨, 보통, 좋음으로 분류)

- 2. 미세먼지와 대기질 관련 빅데이터 Air Korea (자료와 동일)
  날씨 데이터는 기상청 기상자료 개방 포털 (자료와 동일)

- 3. 국내외 기상상태에 따른 미세먼지 생성 > 중국 등 해외 발 미세먼지 (국립환경과학원) → 진짜?

국내외 기상상태에 따른 미세먼지 생성 > 중국 등 해외 발 미세먼지

한·중·일 과학자들은 2000년부터 단계적으로 황산화물, 질소산화물 등 대기오염물질에 대한 연구를 추진했고, 4단계 연구기간인2013~2017년 동안의 초미세먼지(PM2.5)에 대한 연구결과까지 추가하여 이번 보고서를 작성했다.

이번에 발간하는 보고서는 한·중·일 3국의 환경당국 담당자의 검토를 마쳤다. 이 보고서는 당초 지난해 발간될 예정이었으나, 중국측의 이견에 따라 발간이 연기되었다.

괭장히 의심스럽다..

2017년을 대상으로 대기질 모델 기법*을 이용하여 초미세먼지(PM2.5)에 대한 3국 주요도시**의 국내외 영향을 분석한 결과, 자체 기여율은 연평균 기준으로 한국 51%, 중국 91%, 일본 55%로 나타났다.

* 국가별 최적화된 모델 사용에 따라 한국·일본은 CMAQ, 중국은 CAMx를 사용

** 한국 3개(서울/대전/부산), 중국 6개(베이징/톈진/상하이/칭다오/선양/다롄), 일본 3개(도쿄/오사카/후쿠오카)

2017년 연평균 기준으로 중국 배출원에 대한 우리나라 3개 도시에 대한 평균 영향은 32%, 일본에 대한 영향은 25%로 나타났다.

한편, 같은 기준으로 우리나라 배출원의 중국에 대한 영향은 2%, 일본에 대한 영향은 8%로 산정되었고, 일본 배출원의 우리나라에 대한 영향은 2%, 중국에 대한 영향은 1%로 나타났다.

자체 기여율 51%, 중국 32%, 일본 2%, 나머지 기타

결과

- 다중회귀분석 → 매우나쁨 예측 아예 불가능

4.4.1 정밀도(Precision) 비교

<Table 11>에서 보는 바와 같이 예측한 범주 내에서 실제로 예측이 맞은 비율을 나타내는 정밀도 측면에서 살펴보면,

경우 1) '나쁨/매우나쁨' 범주 :

다중회귀 < ANN < SVM

경우 2) '보통/좋음' 범주 :

SVM < 다중회귀 < ANN

Table 11: Performance Comparison

〈Table 11〉 Accuracy Comparison of Multiple Regression, SVM, and ANN Prediction Models

prediction models	Category	Precision	Recall	F-measure
Multiple Regression	bad/very bad	0.602	0.302	0.402
	average/good	0.936	0.981	0.958
SVM	bad/very bad	0.833	0.224	0.354
	average/good	0.930	0.996	0.962
ANN	bad/very bad	0.623	0.506	0.559
	average/good	0.953	0.970	0.962

결론

예측을 위한 모델로는 다중회귀분석, SVM, ANN을 사용하였다. 각 예측모델에 대해서 시험자료를 바탕으로 예측을 수행한 결과 예측 정확도는 '보통/좋음'의 범주에서 다중회귀 : SVM : ANN = 95.8% : 96.2% : 96.2%를 얻어 세 모델 모두 95% 이상의 매우 높은 정확도를 보임을 확인할 수 있었다. 반면에 '나쁨/매우나쁨'의 범주에서는 다중회귀 : SVM : ANN = 40.2% : 35.4% : 55.9%를 보여 세 모델 모두 높지 않은 정확도를 보였으나 ANN 모델의 경우가 상대적으로 높은(55.9%) 정확도를 보였다. 종합적으로 볼 때, 기상환경자료와 머신러닝기법 중의 하나인 ANN을 활용한 미세먼지 예측모델은 매우 효과가 높은 것으로 판단된다.

나쁨/매우나쁨 범주에서 정확도가 높지 않음

결측치 처리

- 2021년 데이터 결측치
- SO2 112
- CO 80
- O3 97
- NO2 80
- PM10 105
- PM25 97
- 강수량(mm) 7810
- 풍속(m/s) 2
- 풍향(16방위) 2
- 일조(hr) 3968

일사(MJ/m2) 3968
적설(cm) 8380
3시간신적설(cm) 8730
전운량(10분위) 2
최저운고(100m) 4212
지면상태(지면상태코드) 8759
지면온도(℃) 5
5cm 지중온도(℃) 5
10cm 지중온도(℃) 5
20cm 지중온도(℃) 5
30cm 지중온도(℃) 5

결측치 2021년이 많아서 2021 기준으로 진행

- 2022년 데이터 결측치
- SO2 21
- CO 21
- O3 21
- NO2 21
- PM10 38
- PM25 25
- 강수량(mm) 2079
- 일조(hr) 1089
- 일사(MJ/m2) 1089
- 적설(cm) 2020
- 3시간신적설(cm) 2145
- 최저운고(100m) 1417
- 지면상태(지면상태코드) 2160

결측치 처리

- 2021년 데이터 결측치
- SO2 112
- CO 80
- O3 97
- NO2 80
- PM10 105
- PM25 97
- 강수량(mm) 7810
- 풍속(m/s) 2
- 풍향(16방위) 2
- 일조(hr) 3968

일사(MJ/m2) 3968
적설(cm) 8380
3시간신적설(cm) 8730
전운량(10분위) 2
최저운고(100m) 4212
지면상태(지면상태코드) 8759
지면온도(℃) 5
5cm 지중온도(℃) 5
10cm 지중온도(℃) 5
20cm 지중온도(℃) 5
30cm 지중온도(℃) 5

결측치 2021년이 많아서 2021 기준으로 진행

강수량, 적설, 3시간 적설 → 0
일조/일사: 시간대에 따른 조건부 처리:
20~06시 0으로 대체, 06~20시 선형 보간

대기 오염 물질 및 온도: 선형 보간 (시계열 특성 반영)

지면상태(지면상태코드), '최저운고(100m): Drop

PM Drop

결측치 처리

- 2021년 데이터 결측치
- SO2 112
- CO 80
- O3 97
- NO2 80
- PM10 105
- PM25 97
- 강수량(mm) 7810
- 풍속(m/s) 2
- 풍향(16방위) 2
- 일조(hr) 3968

일사(MJ/m2) 3968
적설(cm) 8380
3시간신적설(cm) 8730
전운량(10분위) 2
최저운고(100m) 4212
지면상태(지면상태코드) 8759
지면온도(°C) 5
5cm 지중온도(°C) 5
10cm 지중온도(°C) 5
20cm 지중온도(°C) 5
30cm 지중온도(°C) 5

결측치 2021년이 많아서 2021 기준으로 진행

--- 2021 결측치 재확인 ---
SO2 0
CO 0
O3 0
NO2 0
PM10 0
PM25 0
기온(°C) 0
강수량(mm) 0
풍속(m/s) 2
풍향(16방위) 2
습도(%) 0
증기압(hPa) 0
이슬점온도(°C) 0

현지기압(hPa) 0
해면기압(hPa) 0
일조(hr) 0
일사(MJ/m2) 0
적설(cm) 0
3시간신적설(cm) 0
전운량(10분위) 2
중하층운량(10분위) 0
시정(10m) 0
지면온도(°C) 0
5cm 지중온도(°C) 0
10cm 지중온도(°C) 0
20cm 지중온도(°C) 0
30cm 지중온도(°C) 0

나머지 드랍. (2022 결측치 없음)

다중공선성, 상관계수 확인

- 다중공선성 10 넘는 기온, 습도, 증기압, 이슬점온도, 지면온도 5개 변수 제거
- 피어슨 상관계수 9 넘는 NO2와 SO2중 다중공선성 더 높은 NO2 제거

머신러닝 특이사항 - 다중공선성, 상관계수

Isabelle Guyon and André Elisseeff. 2003.
An introduction to variable and feature selection.

- The Journal of Machine Learning Research, Volume 3
-
  (3/1/2003), 1157–1182.

- 2003에 발표된 피인용 23950회 논문
- 상관관계가 있는 변수를 왜 남겨야 하는지 수학적 증명

머신러닝 특이사항 - 다중공선성, 상관계수

3.1 Can Presumably Redundant Variables Help Each Other?

One common criticism of variable ranking is that it leads to the selection of a redundant subset. The same performance could possibly be achieved with a smaller subset of complementary variables. Still, one may wonder whether adding presumably redundant variables can result in a performance gain.

상관 계수가 높아도 변수를 사용한다면 노이즈가 줄어드는 효과가 있다.

머신러닝 특이사항 - 다중공선성, 상관계수

3.2 How Does Correlation Impact Variable Redundancy?

Another notion of redundancy is correlation. In the previous example, in spite of the fact that the examples are i.i.d. with respect to the class conditional distributions, the variables are correlated because of the separation of the class center positions. One may wonder how variable redundancy is affected by adding within-class variable correlation. In Figure 2, the class centers are positioned

상관계수가 1이 아니라면 중복은 아니다
→ 만약 상관 계수가 0.9라면 결정 계수(R2)가 0.81이고, 다른 변수의 변동성을 81% 설명하기 때문에 서로 다른 정보를 가지고 있거나 각자의 노이즈를 가지고 있음.

둘 다 수학적 증명이 있는데 잘 모르겠어요 ㅠㅠ

머신러닝 특이사항 - 다중공선성, 상관계수

5 Feature Construction and Space Dimensionality Reduction

In some applications, reducing the dimensionality of the data by selecting a subset of the original variables may be advantageous for reasons including the expense of making, storing and processing measurements. If these considerations are not of concern, other means of space dimensionality reduction should also be considered.

단순히 기존 변수 중 일부를 골라내는 것 외에, '다른 차원 축소 수단(other means of space dimensionality reduction)'도 반드시 고려해야 한다.

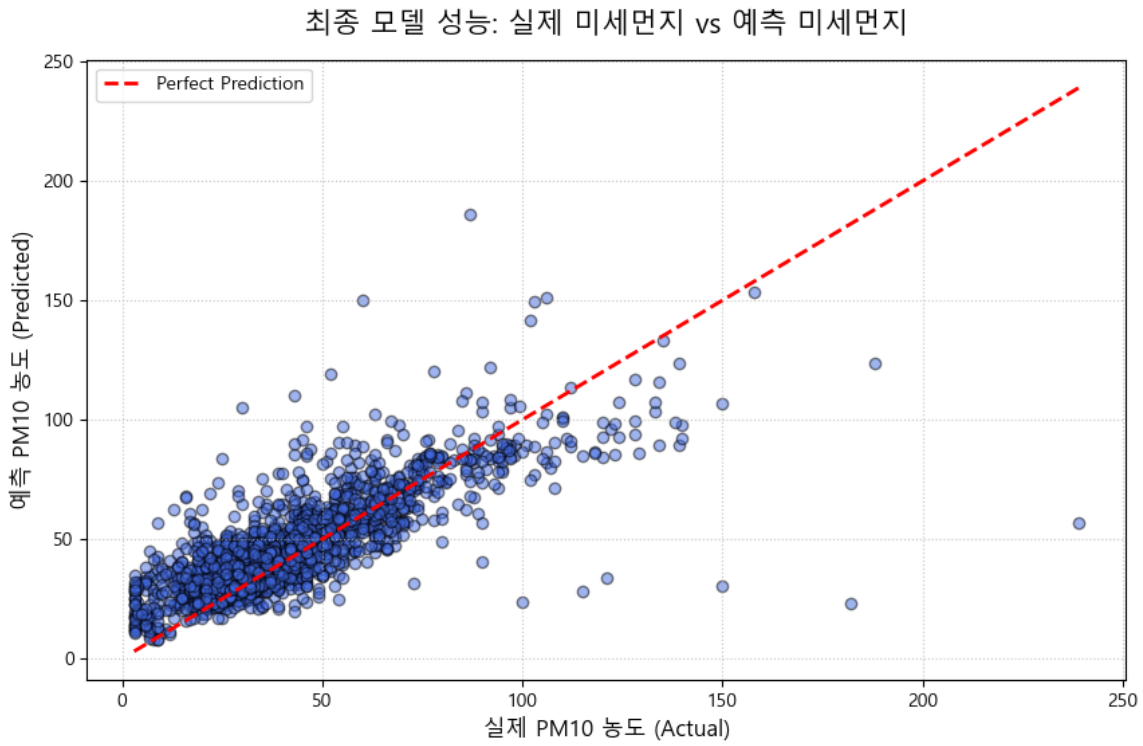
BASELINE 회귀 모델

Model	R2	MAE	RMSE
SVR	0.642489	9.310177	14.168978
Random Forest	0.591861	10.134082	15.139029
XGBoost	0.586849	10.489007	15.231694
Linear Regression	0.409533	12.971278	18.209229
Gradient Boosting	0.094582	12.212526	22.548541

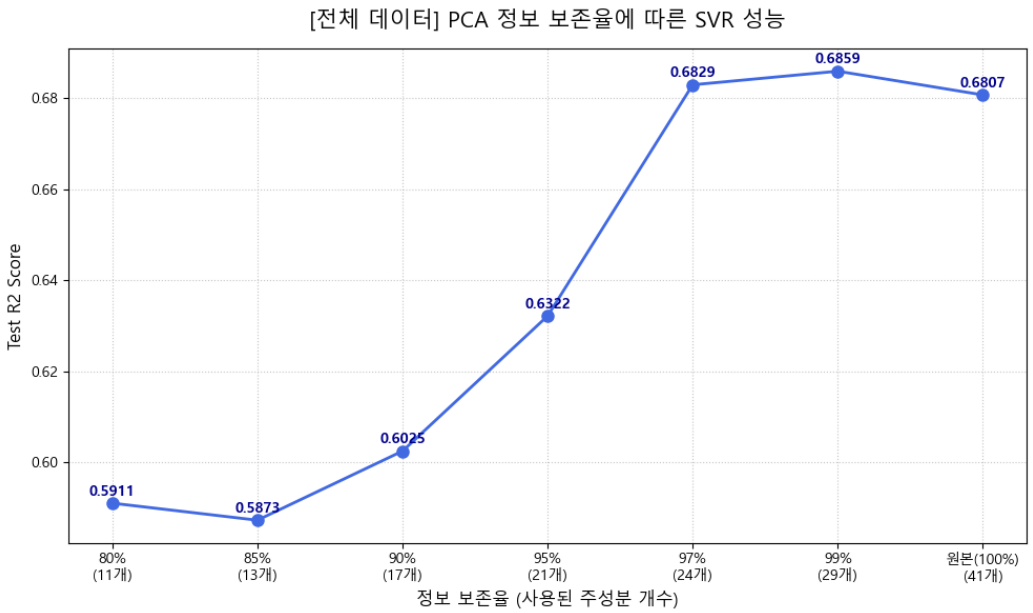
SVR Tuning

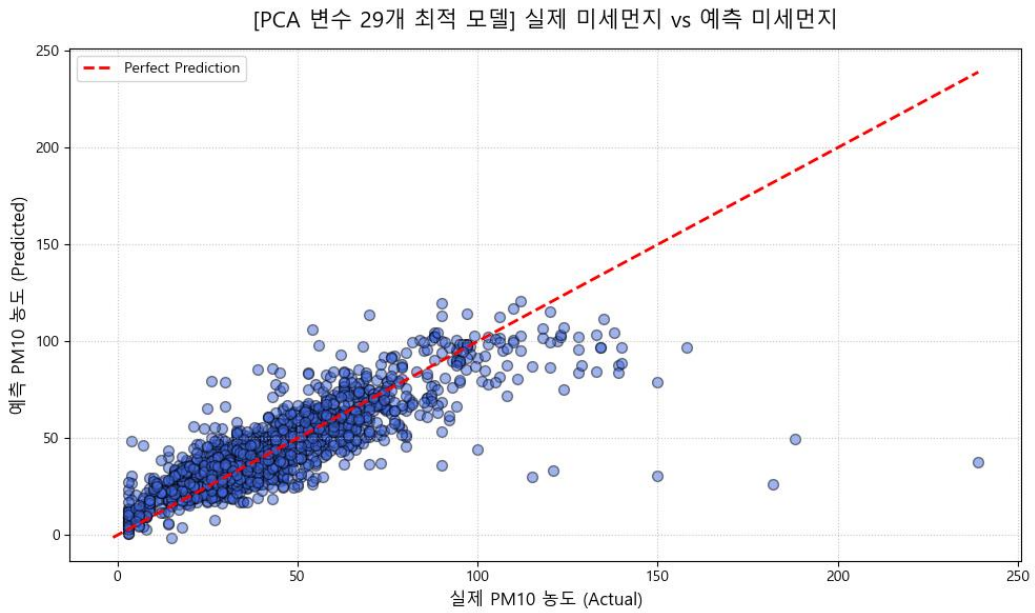
- SVR(kernel='rbf', C=50, epsilon=0.05, gamma=0.005)
- Test R2 Score: 0.6807 Test RMSE: 13.3904

```
param_grid = {
        C': [1, 5, 10, 20, 50, 80, 100],
        epsilon': [0.05, 0.1, 0.15, 0.2],
        'gamma': [0.001, 0.005, 0.01, 0.05, 0.1]
}
```



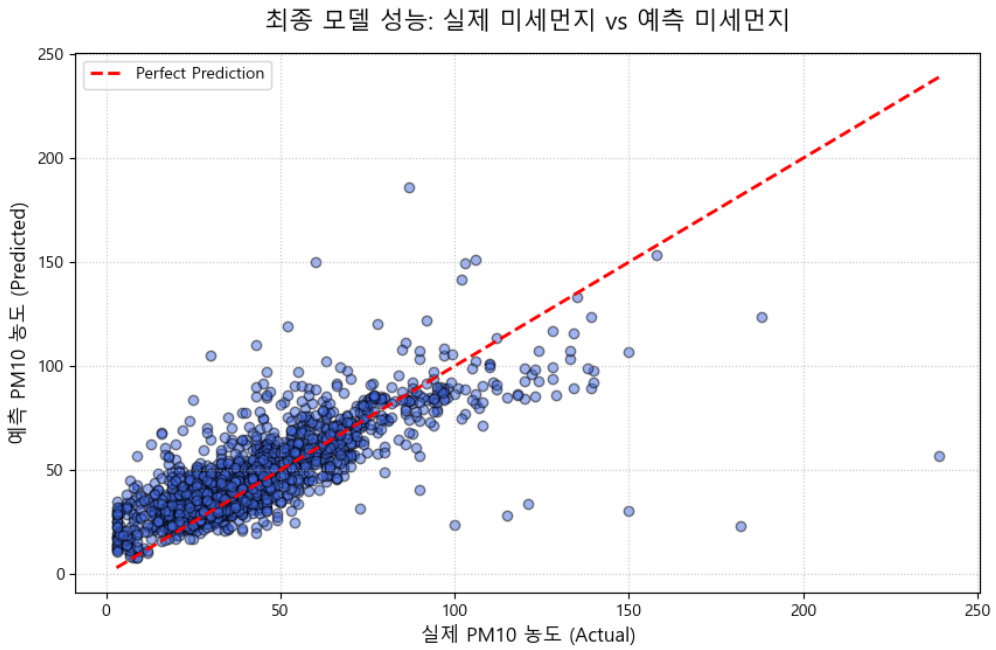
SVR Tuning

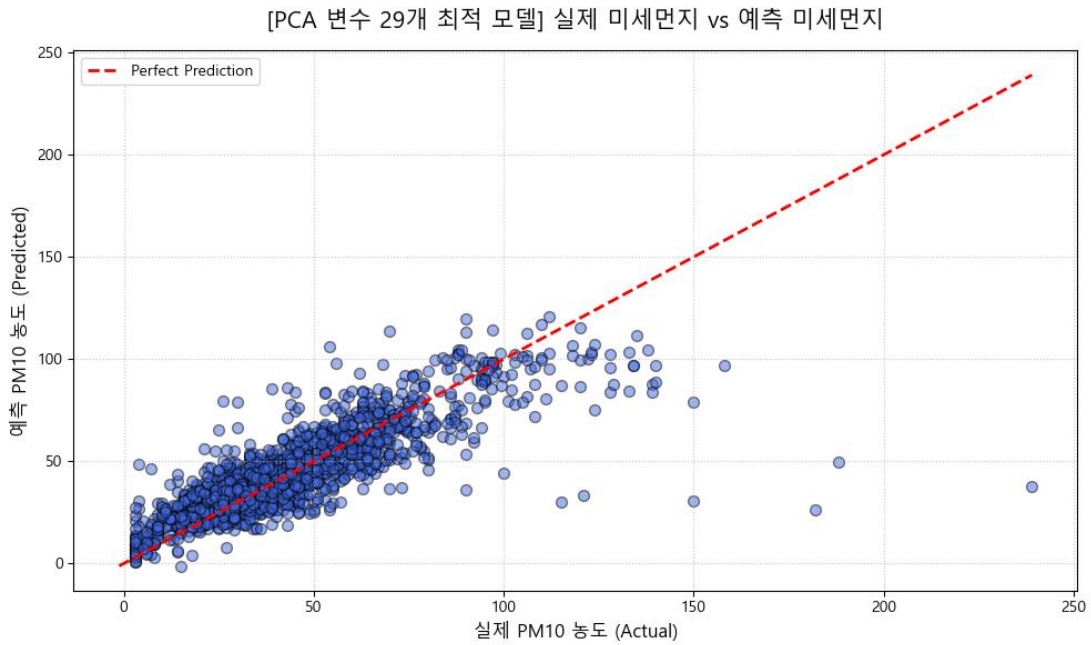




PCA 사용으로 0.6807
→ 0.6859

PCA 비교





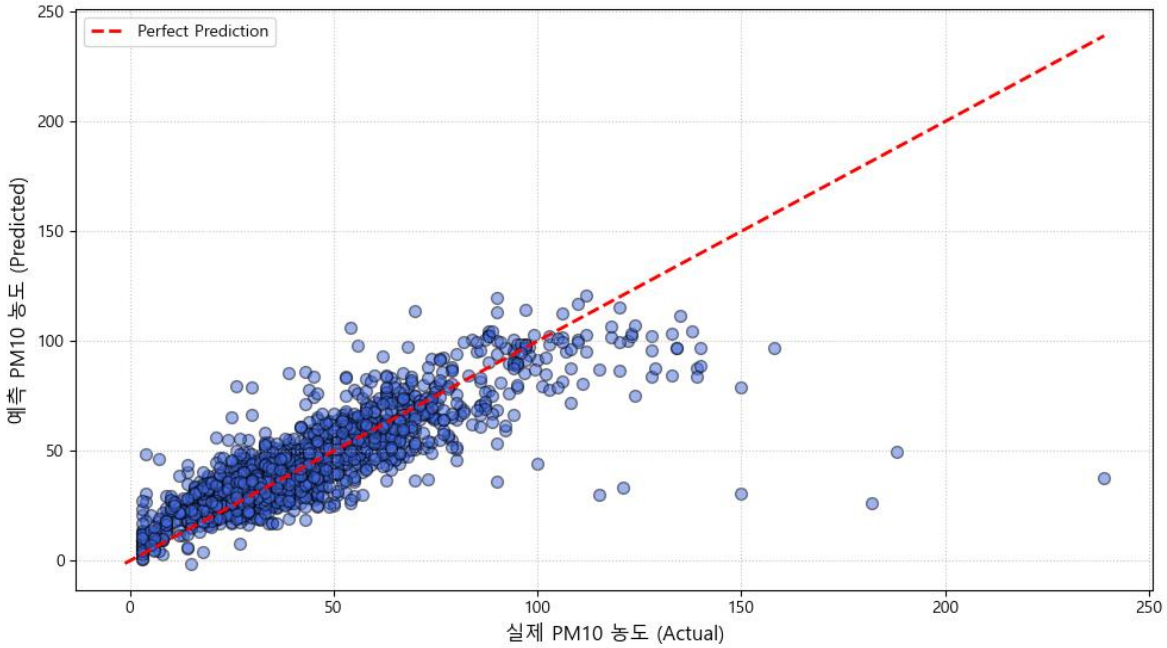
100~150을 기점으로 이상치 예측이 너무 어렵다..
→ 이상치 해결을 어찌 해야하는가

해외발 미세먼지 맛보기

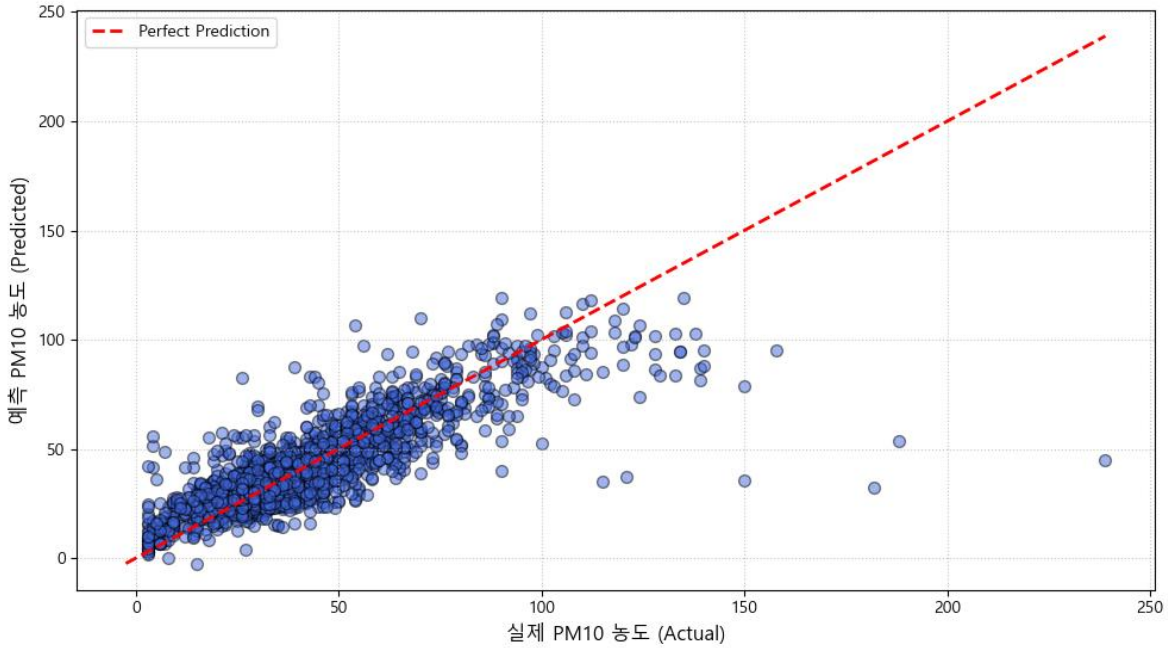
- Air Quality Open Data Platform에서는 전세계의 미세먼지 및 기상 정보를 제공.
- 전일 베이징의 기상 정보로 D-1 베이징 PM10 생성, 데이터셋에 있는 풍향과 풍속을 사용하여 feature 생성
- 기상학 기준: 225도(남서풍) ~ 315도(북서풍)가 중국 대륙에서 불어오는 바람.

ANN 예측과 비교한 시각화 자료

[PCA 변수 29개 최적 모델] 실제 미세먼지 vs 예측 미세먼지



[최종 모델] 실제 미세먼지 vs 예측 미세먼지 (해외 수송량 Flux 반영)

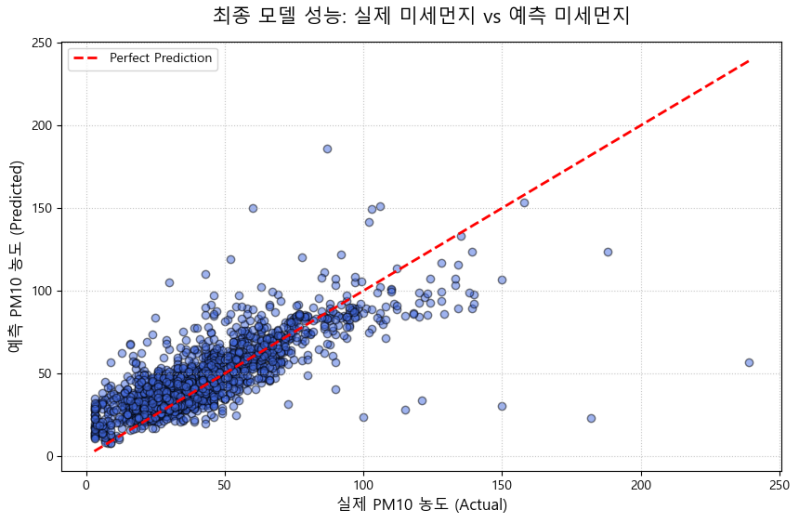


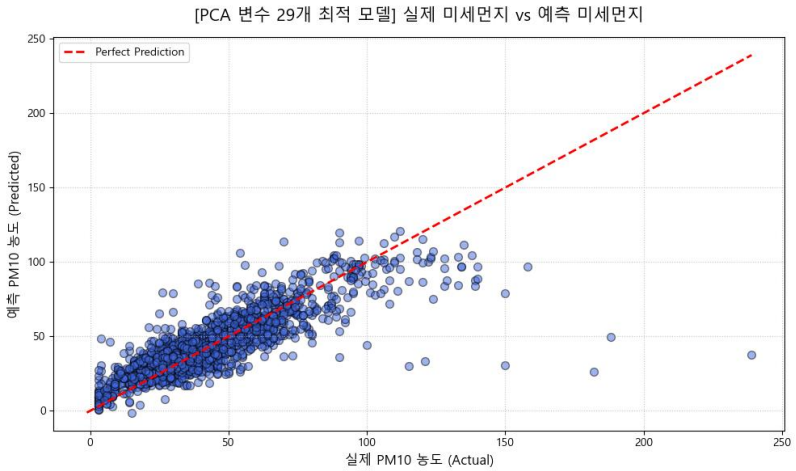
PCA 0.6859

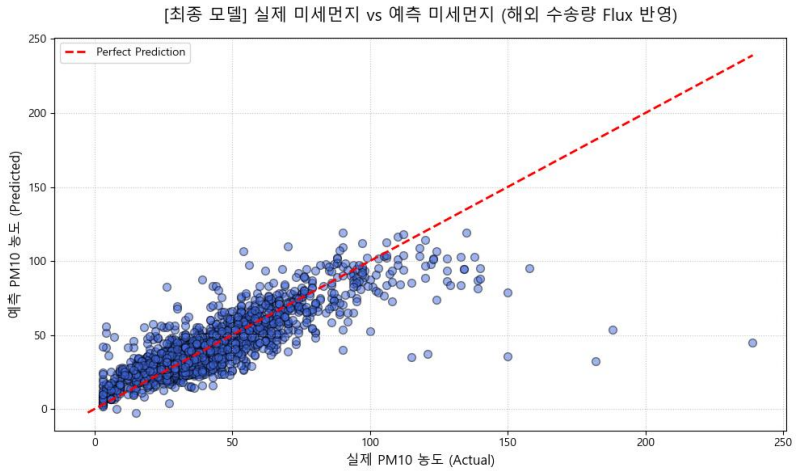
중국발 미세먼지 반영 0.6886

극단치를 조금 개선했다

결론







일반 0.6807, PCA 0.6859, PCA + 해외 정보 0.6886

해외 정보를 더 결합하면 더 높일 수 있지 않을까??

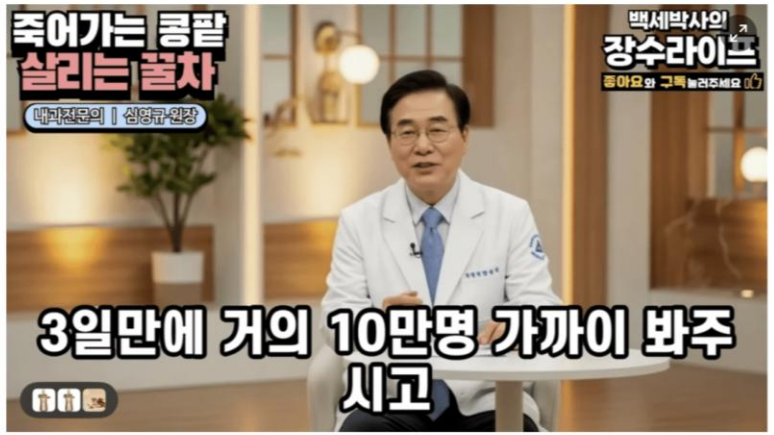
최종 프로젝트 제안

건강

[단독] “원장님 믿고 샀는데”…고령층 쥐고 흔든 ‘AI 가짜 의사’, 이렇게 상술 부렸다

가운 입은 AI “산화된다” 공포 조장…건강 불안한 고령층 타깃
동일 제조사 제품, 포장 방식만 바꿔 55% 가격 ‘뻥튀기’
댓글로 진짜 의사행세 소통까지…현재 해당 채널은 폭파
공정위 ‘AI 광고’ 철퇴 예고…법조계 “사기·의료법 위반 등 중범죄”

김지훈 기자 입력 2026.04.17 16:37 | 댓글 0 가



AI 가상인물을 실제 전문의인 척 둔갑시켜 특정 상품 구매를 유도해 논란인 유튜브채널 영상의 한 장면. 유튜브

엄마가 💙같은 AI 의사 채널에 속았다 2026.04.16 22:09

선술집 조회 수 694196 추천 수 2634 댓글 460

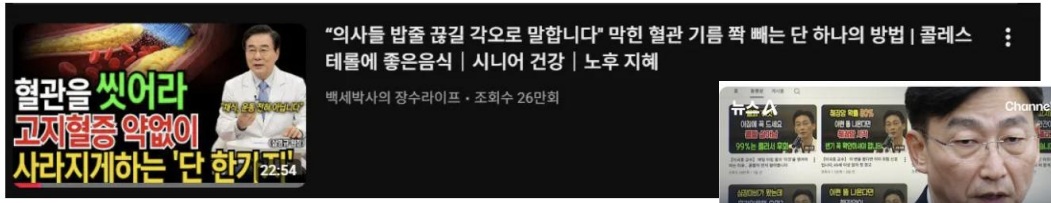
https://www.fmkorea.com/best/9716467789 복사

엄마가 쿠팡으로 뭔 4만원도 넘는 석류즙을 사서

뭔 ㅅㅂ 석류즙이 4만원이야 하고 물어보니까 유튜브를 보고 링크눌러서 샀다고 하더라고

쿠팡 들어가보니까 비슷한 제품 중에 로켓 달린거(쿠팡직매입) 보다 2배 넘게 비싼거임.

뭐지 하고 엄마가 봤다는 링크 받아서 들어가봄.



조회수가 26만이나 됨;; 근데 영상 보니까 AI인거임.



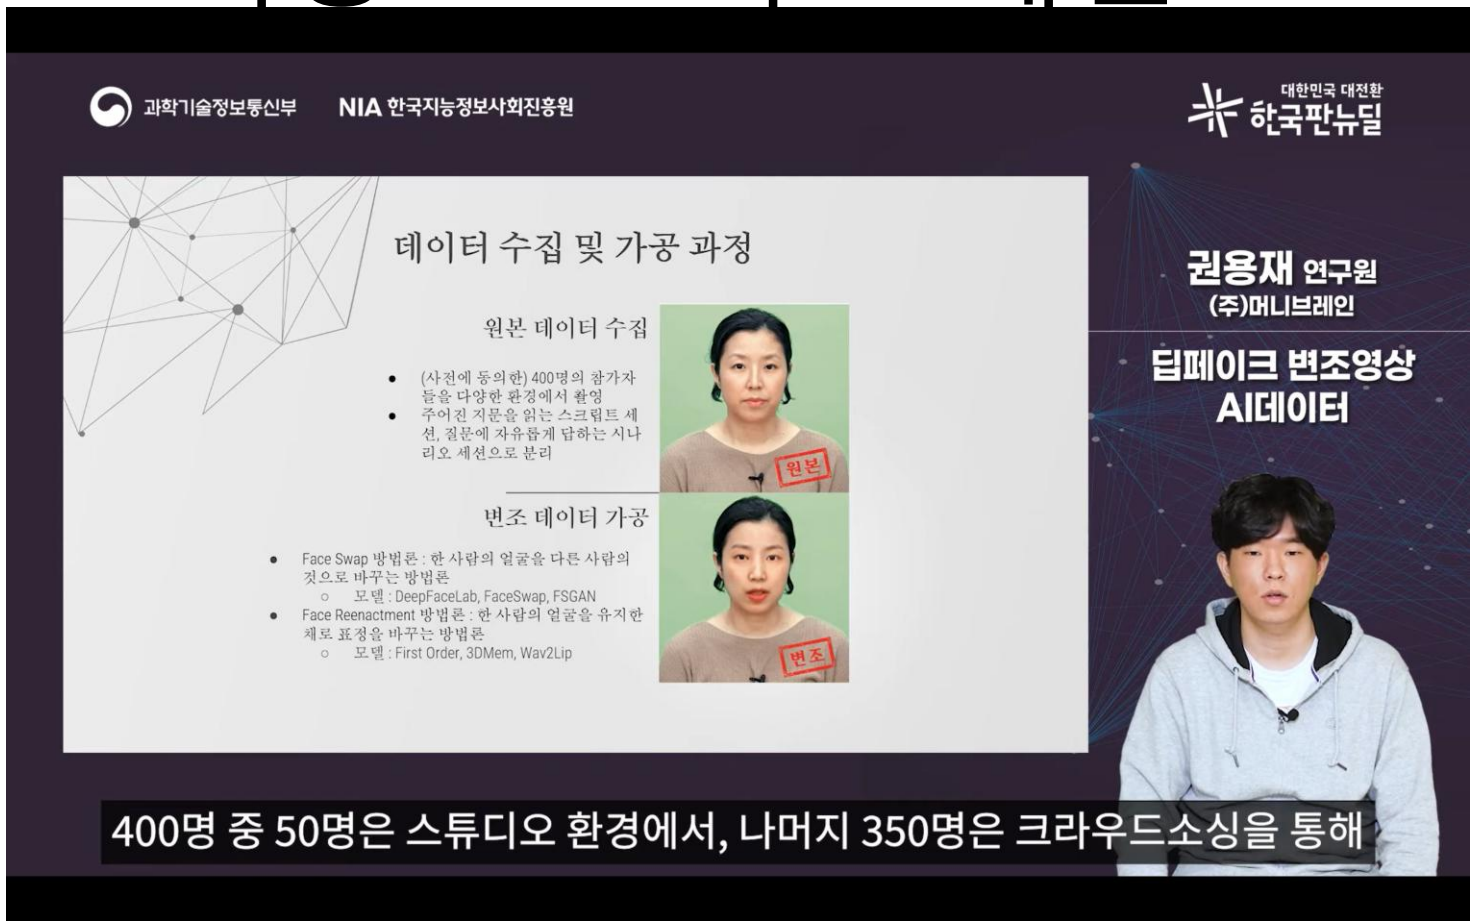
이국종 교수의 건강정보?...딥페이크 영상이었다 / 채널A / 뉴스A
2.8천 • 1개월 전
채널A News
이국종 교수의 건강정보?..딥페이크 영상이었다 혹시 이국종 교수가 건강정보를 알려 주는 영상 보신 적 있으십니까. 조회 수가 ...



"이국종 교수입니다"...AI 딥페이크에 수십만 명 속았다 [투데이 '픽'/iMBC연예뉴스]
688 • 1개월 전
iMBC연예
이국종 #딥페이크 #AI #iMBC연예뉴스 ☆iMBC 연예뉴스 공식 홈페이지 ▷ iMBC연예 : http://enews.imbc.com ☆구독! 좋아요!

딥페이크 구분이 정말 쉽지 않다

최종 프로젝트 제안



Aihub 딥페이크 변조 영상

영상ID	영상의 고유 번호
UUID	촬영자의 고유 번호
촬영시작	촬영 시작 날짜를 기재
감정분류	neutral, negative, positive의 3감정 기재
진위분류	영상이 원본 영상인지 합성 영상인지를 기재
안경여부	촬영자가 안경을 착용했는지 여부를 기재
idle	말을 하지 않고 단순히 정면을 바라보는 영상인지 여부를 기재
내외부	촬영장소가 실내인지 실외인지를 기재
조명종류	촬영의 조명이 자연광인지 인공광인지를 기재
조명수준	조명수준을 밝음, 중간, 낮음 으로 분류하여 기재
소음수준	주변 환경 소음을 조용, 중간, 심함으로 분류하여 기재

사람의 경우 혈류에 의해 얼굴의 밝기가 계속적으로 변함.
비접촉식 rPPG(원격 광혈류측정) 기술을 이용하여 유튜브 영상 내 딥페이크 판별

최종 프로젝트 제안




Deep-Check: AI 스캠 탐지기
94%
분석 완료
딥페이크일 확률
94%
rPPG 기반 생체 혈류 신호가 거의 감지되지 않으며,
표정과 입 모양의 인위적인 불일치가 확인됩니다.
사기 광고 및 구매 주의!
자녀에게 확인 요청
구매 주의 사항 확인
학습하기